

RELATÓRIO — OUVIDORIA INTELIGENTE

Triagem Semântica de Manifestações Cidadãs

Projeto de Processamento de Linguagem Natural / Engenharia de IA

1. Contexto e objetivo

O projeto desenvolve um protótipo de triagem semântica para manifestações cidadãs, utilizando representações vetoriais, similaridade de cosseno, chunking, detecção de duplicatas e busca semântica. A base possui 40 manifestações identificadas de M001 a M040, cada uma com categoria oficial e texto livre.

O objetivo é complementar a abordagem baseada em palavras-chave, permitindo identificar relações semânticas, manifestações potencialmente duplicadas e textos longos que precisam ser divididos em partes menores.

2. Base de dados

A distribuição das categorias oficiais fornecidas é: educação: 7, infraestrutura: 9, meio ambiente: 8, saúde: 9, segurança: 7. Os textos e categorias foram utilizados conforme fornecidos.

3. Análise comparativa

Foram utilizadas BoW e TF-IDF como representações esparsas e embeddings multilíngues como representação densa. BoW representa a ocorrência dos termos; TF-IDF atribui pesos considerando a frequência dos termos no corpus; embeddings representam relações semânticas em um espaço vetorial.

Par	BoW	TF-IDF
M003 × M017	0.0000	0.0000
M008 × M022	0.0000	0.0000
M008 × M031	0.0000	0.0000

Os pares M003 × M017 e M008 × M022 foram definidos no desafio como exemplos de manifestações semanticamente relacionadas. M008 × M031 funciona como contraste. A comparação mostra a diferença entre métodos baseados principalmente na sobreposição lexical e uma representação semântica baseada em embeddings.

4. Detecção de duplicatas

Foi implementada a função `detectar_duplicatas(textos, limiar=0.85)`. Ela gera embeddings normalizados, calcula similaridade de cosseno e retorna os pares com similaridade acima ou igual ao limiar.

O valor 0,85 foi utilizado porque é o limiar especificado no desafio. O notebook também calcula os percentis 90 e 95 da distribuição de similaridades para permitir análises adicionais.

O material fornecido informa aproximadamente 15% de duplicatas semânticas, mas não apresenta uma lista explícita dos pares verdadeiros. Portanto, não foi criado um gabarito artificial para falsos positivos e falsos negativos; essa validação deve ser feita comparando os pares detectados com uma referência manual.

5. Chunking das manifestações longas

As cinco manifestações mais longas são identificadas automaticamente pelo número de caracteres. O projeto testa duas configurações do `RecursiveCharacterTextSplitter`: `chunk_size=250` com `overlap=40` e `chunk_size=450` com `overlap=80`.

ID	Categoria	Caracteres
M037	meio ambiente	698
M036	educação	685
M039	saúde	517
M038	infraestrutura	509

M040	meio ambiente	504
------	---------------	-----

O overlap preserva parte do contexto entre chunks consecutivos, reduzindo a chance de separar uma informação importante exatamente na fronteira. Como consequência, overlap maior também produz mais conteúdo repetido e maior custo de processamento. A comparação das duas configurações permite observar esse compromisso.

6. Espaço vetorial

Os embeddings das manifestações e dos chunks são projetados em duas dimensões por PCA. Para as manifestações, os pontos são apresentados considerando a categoria oficial. Essa visualização permite observar proximidades semânticas e comparar a organização vetorial com os rótulos administrativos.

7. Aplicativo Streamlit

O aplicativo possui quatro áreas principais: Busca Semântica, Base Completa, Espaço Vetorial e Chunking. A barra lateral permite selecionar o modelo de embedding e o valor de Top-K.

A Busca Semântica recebe uma descrição livre e retorna as manifestações mais similares, com indicação visual para scores acima de 0,7, acima de 0,5 e demais resultados. A Base Completa exibe os registros e permite gerar a matriz de similaridade. O Espaço Vetorial apresenta a projeção PCA. O módulo Chunking permite inserir uma manifestação longa, escolher uma estratégia e visualizar os chunks.

8. Conclusão

O protótipo implementa o fluxo solicitado: comparação de representações, similaridade semântica, detecção de duplicatas, chunking de textos longos, visualização vetorial e aplicação interativa. BoW e TF-IDF são baselines simples e interpretáveis, porém dependem da sobreposição lexical. Embeddings permitem representar relações semânticas de forma mais adequada para busca e duplicatas, embora os resultados dependam do modelo e do limiar escolhido.

As principais limitações são a dependência do modelo de embeddings, a necessidade de validar empiricamente o limiar de duplicatas e a ausência, na base fornecida, de uma lista explícita de pares verdadeiros para medir formalmente falsos positivos e falsos negativos.

9. Execução

No Google Colab ou Jupyter, instale as dependências de requirements.txt e execute os notebooks `analise_comparativa.ipynb`, `deteccao_duplicatas.ipynb` e `chunking_manifestacoes.ipynb`. Para a interface, execute: `streamlit run ouvidoria.py`. Na primeira execução, os modelos Sentence-Transformers podem precisar ser baixados.